Primer ejercicio práctico: Implementación de un analizador morfológico básico mediante expresiones regulares en Python

Ariadna Frutos Javierre

19 de diciembre de 2018

1 Introducción

El texto que presentamos a continuación describe el proceso seguido para desarrollar, implementar y evaluar un analizador morfológico sobre textos dentro del dominio informático, tal como se propone en el enunciado del Primer ejercicio práctico del Curso de Procesamiento del Lenguaje Natural 2018/19. La aproximación seguida ha sido la de combinar el uso de expresiones regulares, que permiten dar generalidad a la herramienta, con la creación de un diccionario, para mejorar la efectividad. La herramienta se ha desarrollado en Python, empleando librerías NLTK y partiendo de un programa base proporcionado por el profesorado del curso.

2 Creación del programa

2.1 Estrategia

2.1.1 Segmentación y etiquetado del texto de entrenamiento

Para el desarrollo de la herramienta se ha partido de un texto del dominio de la informática, al que llamaremos *texto de entrenamiento*. Tras un par de lecturas para familiarizarnos con él, se ha procedido a segmentarlo haciendo uso de la función *tokenize* de NLTK, incluida en el programa base. Esta función proporciona el listado de las palabras (*tokens*) que conforman el texto, ordenadas según su aparición. Nótese que usamos aquí el término *palabra* en el sentido inglés de *token*, es decir, se consideran palabras todas las cadenas separadas por espacios en blanco u otros límites establecidos por la función *tokenize*, incluyendo los signos de puntuación.

El texto de entrenamiento está formado por 661 palabras, de las cuales solamente 254 son distintas. Sin embargo, en el análisis morfológico hemos tenido en cuenta todas las palabras, incluyendo repeticiones, ya que palabras iguales en forma pueden pertenecer a categorías distintas en función del contexto. Para agilizar el análisis nos hemos ayudado de la versión online del programa FreeLing[Padró 2012], una potente herramienta que realiza, entre otras tareas, análisis morfológico para una multitud de lenguas. A parte de indicar las distintas categorías y atributos que una misma palabra puede tomar, FreeLing proporciona la probabilidad con que se da cada una, lo cual nos ha sido muy útil para tomar decisiones en casos de ambigüedad. El listado de las palabras del texto, junto con las frecuencias con que aparecen, las categorías más probables según FreeLing y las categorías finales asignadas, basándonos en el contexto, pueden consultarse en el siguiente enlace:

https://docs.google.com/spreadsheets/d/1FqaCvrKvj0njJ0IehGdPyo_4l03DJDO0zdn5Gr9ujuE/

El juego de etiquetas empleado ha sido el siguiente:

A parte de la categoría, en las etiquetas morfológicas de los nombres se han incluído los atributos tipo, género y número, y para los verbos, los atributos tipo, modo, tiempo, persona, número y género (este último, solo en los participios). En la tabla, indicamos los atributos con el símbolo genérico X; la

Table 1: Etiquetas empleadas

Categoría	**Etiqueta**
adverbio	ADV
artículo	ART
adjetivo	ADJ
determinante	DET
pronombre	PRON
conjunciones	CONJ
numerales	NUM
interjecciones	INT
abreviaturas	ABRV
preposiciones	PREP
signos de puntuación	PUNT
nombres	NXXX
verbos	VXXXXXX

notación seguida ha sido la propuesta por el grupo EAGLES, http://www.cs.upc.edu/~nlp/tools/parole-sp.html. Para el resto de categorías no se han incluído los atributos. Esta simplificación se justifica por el hecho de que solo los nombres y los verbos presentan flexión con información semántica y, según el enunciado de la práctica, el objetivo de la herramienta es la implementación de un sistema automático de consultas informáticas, no un analizador morfológico que dé todos los detalles. Las categorías para las que no se han especificado estos atributos, o bien no tienen flexión, o bien la tienen por motivos de concordancia, pero no aportan información semántica relevante (más allá de facilitar, en algunos casos, la desambiguación de referentes, que aquí no se considera).

2.1.2 Ampliación del corpus

Existen una serie de palabras comunes en la lengua española que, por pertenecer a categorías cerradas o limitadas, es sencillo añadir a un corpus dado y pueden mejorar significativamente la eficiencia de un sistema automático. Hemos considerado interesante ampliar nuestro corpus, basado en el texto de entrenamiento, con algunas palabras pertenecientes a estos grupos. En concreto, hemos añadido:

- preposiciones
- conjunciones
- signos de puntuación
- pronombres
- adverbios no acabados en *-mente*

El efecto de esta ampliación en los resultados del analizador se comentan en el apartado 3.1.1.

2.1.3 Generación de expresiones regulares e inclusión de palabras al diccionario

Una vez realizado el análisis morfológico, se ha procedido a valorar, para cada palabra, la posibilidad de generar una expresión regular que la contemple o, en caso de no ser posible, la necesidad de incluirla

en el diccionario. Las expresiones regulares se han intentado escribir de la forma más general posible, de modo que incluyan tanto las palabras del texto de entrenamiento como otras similares que puedan aparecer en nuevos textos.

La figura 1 muestra, en un diagrama de flujo, el proceso seguido para evaluar las distintas posibilidades según el tipo de palabra. Como puede verse, se ha procedido de modo distinto para los nombres y verbos, para los cuales había que incluir atributos, que para el resto de categorías. De estas últimas, las palabras que no admiten flexión ni son derivadas (conjunciones, interjecciones, abreviaturas, preposiciones, numerales, signos de puntuación y algunos determinantes y pronombres), si son susceptibles de aparecer en nuevos textos, se han añadido directamente al diccionario, ya que no siguen patrones característicos que permitan identificarlas de forma automática. Los adverbios también se han incluído en el diccionario, excepto los terminados en *-mente*, para los cuales se ha generado una expresión regular. En cambio, para las palabras que admiten flexión o son derivadas, se ha optado por generar expresiones regulares. En general, para los pronombres no enclíticos y los determinantes se ha optado por generar una expresión para cada lema, para mantener una cierta estructura dentro del programa que facilite la interpretación humana del código. Por ejemplo, se han generado expresiones distintas para los determinantes indefinidos *un*, *algún* y *ningún*, a pesar de las similitudes que presentan sus terminaciones. (Se ha hecho alguna excepción, como en el caso de los pronombres *nosotros* y *vosotros*, para mostrar la versatilidad de las expresiones regulares.) Los artículos se han etiquetado a parte, pero se ha aplicado el mismo criterio. Así, se ha optado por incluir el artículo *el* en la expresión que define el resto de artículos (*la*, *los*, *las*) mediante el operador "|" (disyunción), en lugar de añadirlo en el diccionario. Aquí nos hemos encontrado con el problema de la ambigüedad, ya que hay varios pronombres y determinantes que coinciden en forma. La categoría asignada en estos casos ha sido la correspondiente a la forma que se presenta mayoritariamente en nuestro texto de entrenamiento, así como en el corpus de FreeLing.

Los determinantes son un grupo limitado dentro de la lengua española. Tiene sentido, pues, especificarlos uno a uno, agrupándolos según su lema. Pero el número de adjetivos es ilimitado: se trata de un grupo muy grande de elementos que, además, no es cerrado, es decir, se crean nuevos adjetivos contínuamente. Por este motivo la identificación de adjetivos concretos no es eficiente a la hora de programar un analizador morfológico. El origen derivativo de muchos adjetivos permite identificarlos a partir del sufijo que presentan. Tras el análisis de los adjetivos del texto de entrenamiento, se han identificado los siguientes sufijos propios de adjetivos: *-ado*, *-ico*, *-ivo*, *-ífico*, *-al*, *-ante*, *-able* e *-ible*. Para cada una de ellos se ha creado una expresión regular que incluye las distintas formas de género y número, excepto para *-ífico*, por estar quedar definido en la expresión correspondiente a *-ico* [1]. Para los adjetivos que no presentaban una terminación característica, se ha creado una expresión específica que incluyera las distintas formas de flexión.

En la identificación y etiquetación de nombres y verbos se ha procedido de modo distinto. Como ya se ha dicho, estas dos categorías presentan flexión con contenido semántico, de manera que es importante detectar, a parte de la categoría, otros atributos de la forma analizada. Para estos atributos existen patrones de flexión que pueden ser reproducidos mediante expresiones regulares. Por ejemplo, la terminación de la tercera persona del singular del presente de indicativo de los verbos regulares del paradigma *-ir* (*requerir*) es *-iere*. Esta terminación es característica de esta forma verbal, y según el diccionario inverso Stilus [[Meaning Cloud]], no se presenta en otras categorías. Ahora bien, no siempre es así: algunas terminaciones correspondientes a categorías o atributos distintos coinciden. Por ejemplo, no se puede saber, si no es por conocimiento explícito de la palabra *ejecutar* o por el contexto, si la terminación *-a* de *ejecuta* corresponde a la tercera persona del singular del presente de indicativo de un verbo, o a la terminación de un nombre femenino, como en *fruta*, *cicuta* o *permuta*. Tampoco se puede discriminar, sin conocer la palabra y, en muchos casos, el contexto, si una palabra terminada en *-ado*, como *integrado, cambiado* o *aterciopelado*, es un participio o un adjetivo. Para las palabras cuyas terminaciones, aun siendo características de una categoría, no son exclusivas de esta,

[1] Al igual que se ha hecho con preposiciones, conjunciones, etc., se podría haber ampliado el repertorio de terminaciones de adjetivos añadiendo a la lista los sufijos más frecuentes en la lengua española, ya que este sí que es un grupo limitado. En esta ocasión no se ha hecho; se considera incluirlos en trabajos futuros.

se ha optado por una de estas tres opciones:

a) generar una expresión regular, si la categoría en cuestión es altamente probable para esa terminación,

b) incluirla en el diccionario, si es probable que la palabra aparezca en nuevos textos,

c) ignorarla, y permitir que el programa se equivoque al analizarla, en otros casos.

2.1.4 Ordenación de reglas regulares

En el programa base, la asignación de etiquetas se realiza mediante la función *RegexpTagger*. Esta función asigna la etiqueta mencionada en una expresión regular si la palabra analizada cumple la regla descrita por esta. Las expresiones se activan por orden de precedencia, es decir, cuando una palabra coincide con una expresión, le es asignada esa categoría y ninguna más. Por esto es muy importante ordenar las expresiones de más restrictiva a más general. Es decir, la preposición *para*, o las formas femeninas de los determinantes *una*, *alguna*, etc. deben mencionarse antes que la regla general para los sustantivos femeninos acabados en *-a* o, de lo contrario, se les asignaría la etiqueta NCFS (nombre común femenino singular).

2.2 Consideraciones

Tras mostrar la estrategia general, comentamos aquí algunas consideraciones que se han tenido en cuenta a la hora de tomar decisiones y establecer prioridades.

2.2.1 Formas iguales con categorías distintas

Para términos ambiguos (como *la*, que puede ser artículo o pronombre, o las palabras terminadas en *-ado*, que pueden ser participios o adjetivos), se han tenido en cuenta dos factores: la categoría más probable según FreeLing, y la categoría más frecuente en nuestro texto de entrenamiento. En la mayoría de casos ambas coinciden (véase el enlace proporcionado en el apartado 2.1.1), y la elección ha sido esa. En los casos en que no coincidían, se ha optado, en cada caso, por la categoría que hemos considerado más oportuna dado el dominio en que estamos realizando el estudio, el de la informática. Así, hemos etiquetado la palabra *computadora* como nombre, y no como adjetivo. En cambio, la palabra *estado*, que en nuestro texto aparece como participio del verbo estar, la hemos etiquetado como nombre siguiendo el criterio de FreeLing, que otorga una probabilidad de 0.65 a esta categoría y 0.35 a la de verbo. El verbo *estar* no es una palabra específica del dominio de la informática, de modo que las probabilidades de FreeLing, que corresponden a un dominio general, son aplicables.

Otra divergencia importante ha sido la etiquetación de las palabras terminadas en *-ado*. En la mayoría de los casos FreeLing asigna como más probable que se trate de participios, mientras que en nuestro texto, la mayoría de veces la palabra en cuestión, en su contexto sintáctico, es un adjetivo. Aquí hemos optado, pues, por la etiqueta adjetivo.

2.2.2 Generalización de patrones

A la hora de generalizar patrones en las expresiones regulares se han aplicado los siguientes criterios:

- Para simplificar la tarea, no se han excluído de los patrones formas inexistentes en la lengua castellana. Por ejemplo, la expresión regular insertada para el determinante indefinido *algún/alguna/algunos/algunas* es /\balg[uú]na?(os|s)?$/. Esta expresión acepta los patrones indicados, pero también las formas incorrectas algú, algúna o *algunaos*. Para nuestro fin, la implementación de un sistema automático que atienda consultas, consideramos que esta aproximación no es problemática; de hecho, puede ser hasta beneficiosa. No sería así si el objetivo fuera la creación de un corrector automático.

- Sí se ha intentado, en cambio, que los patrones no definan palabras ortográficamente correctas de categoría distinta a la asignada. Sin embargo, se ha perseguido conseguir un equilibrio entre

efectividad y generalidad, de modo que no siempre se ha apostado por la efectividad. Para conseguir este equilibrio, se ha tenido en cuenta la probabilidad de que una palabra mal etiquetada por una expresión generalizada se dé en el dominio de la informática. Por ejemplo, la expresión /.*iene$/ define las formas verbales *tiene*, *viene* y análogas, para las cuales se ha creado, pero también el nombre *higiene*. Sin embargo, como la palabra *higiene* es poco probable en nuestro dominio, se ha optado por la generalidad.

- Para valorar la generalidad de un patrón determinado para una categoría nos hemos ayudado de la herramienta online Diccionario Inverso Stylus [Meaning Cloud], que permite búsquedas de palabras según su terminación.
- Las excepciones de las reglas regulares con probabilidad no despreciable de aparecer en nuevos textos se han incluído en el diccionario. Es un ejemplo el nombre *dispositivo*, que la expresión regular /.*iv[oa]s?$/ categorizaría como adjetivo.

2.2.3 Priorización de reglas

Para la ordenación de las expresiones regulares se ha seguido la siguiente priorización:

1. Las expresiones que definen formas distintas de palabras con un mismo lema se han puesto al principio de todo, por ser las más específicas.
2. A continuación se han incluído las expresiones correspondientes a terminaciones típicas, discriminatorias, de adjetivos, verbos y nombres femeninos no acabados en -*a*, así como la de los adverbios acabados en -*mente*.
3. Después se han incluído expresiones que definen las terminaciones típicas, pero no discriminatorias, de los nombres.
4. Finalmente se ha incluído la expresión general /.*$/, que asigna la categoría por defecto (en nuestro caso, NCMS, "nombre común masculino singular") cuando la palabra analizada no coincide con ninguna de las reglas anteriores.
5. Los términos comunes, que no son "nombre común masculino singular", ni siguen un patrón específico, se han añadido al diccionario.

2.2.4 Casos particulares

Se describen a continuación algunos casos que consideramos oportuno mencionar.

- Adjetivos/participios acabados en -*ado*: Aunque FreeLing etiqueta como "participios" la mayoría de casos, nosotros hemos optado por etiquetar las terminaciones -*ado* como adjetivo, por ser esta la categoría mayoritaria en nuestro texto de entrenamiento.
- Locuciones: No hemos considerado locuciones como *dentro de*, *así y como*, *por lo general*, etc., ya que la función *tokenizer* no las contempla y separa los términos que las forman. En lugar de ello, se han etiquetado los elementos *dentro*, *de*, *así*, etc.

Para otros comentarios sobre casos concretos, pueden consultarse las notas incluidas en el programa.

2.2.5 Resultados para el texto de entrenamiento

La tabla 2 muestra un resumen de los resultados obtenidos por el analizador sobre el texto de entrenamiento.

Como puede apreciarse, el porcentaje de aciertos es muy alto. Esto es normal, ya que se ha programado el analizador para que así sea, maximizando la efectividad (sin descuidar, como se ha

Table 2: Resultados del analizador morfológico sobre el texto de entrenamiento

Número de palabras (*tokens*)	661
Número de palabras distintas	254
Número de aciertos	652
Porcentaje de aciertos	98,6%

Table 3: Resultados del analizador morfológico sobre el texto de entrenamiento

Número de palabras (*tokens*)	201
Número de palabras distintas	94
Número de palabras revisadas	50
Número de aciertos	45
Número de aciertos debidos a la ampliación	0
Porcentaje de aciertos	90%

dicho, la generalidad). El éxito de la tarea no viene dado por los resultados del sistema sobre el texto con el que se ha trabajado, sino con textos nuevos, como se verá en el apartado siguiente. Puede consultarse el resultado detallado en el enlace proporcionado en el apartado 2.1.1.

3 Evaluación del programa

En esta sección analizamos los resultados obtenidos por el sistema que hemos programado sobre un nuevo texto, al que llamaremos *texto de test*. Lo único que sabíamos de este texto antes de aplicar nuestra herramienta era que pertenecía, igual que el texto de entrenamiento, al dominio de la informática.

Una vez realizado el análisis automático del texto de test, hemos hecho una revisión manual de las 50 primeras palabras. La tabla 3 muestra el resumen de los resultados obtenidos. Los resultados detallados pueden consultarse en el enlace proporcionado en el apartado 2.1.1, junto al análisis realizado por la herramienta FreeLing (etiqueta más probable).

amiento.

Vemos que el porcentaje de aciertos ha bajado significativamente: del 98,6% al 90%. Sin embargo, consideramos que es un porcentaje bastante bueno, dado el pequeño corpus con que hemos realizado el entrenamiento.

3.1 Análisis de los resultados

3.1.1 Importancia de la ampliación del corpus

Contrariamente a lo que esperábamos, la ampliación del corpus no ha tenido un efecto muy significativo. Entre las primeras cincuenta palabras del texto de test, ninguna ha coincidido con las palabras añadidas. De hecho, en todo el texto hay tan solo dos palabras que pertenecen a esta ampliación: *porque* y *también*. Sin embargo, el texto contenía un determinante que no habíamos previsto, *diversos*, y un pronombre, *esto*. El sistema a etiquetado *diversos* con la etiqueta por defecto para las terminaciones -*s*, NCMP, mientras que *esto* ha sido etiquetado como PRON, por estar definido en una de las expresiones regulares implementadas, \best?[eao]?s?$\. La no inclusión de *esto* en el diccionario ha sido, ciertamente, un descuido, ya que era una excepción de la expresión regular, de modo que debería haber sido incluida en el diccionario.

3.1.2 Multilinguismo

Las primeras 50 palabras del texto de test no incluyen palabras inglesas, pero sí el resto del texto: *software*, *bug*, *bugs* y *debugging*. La primera, software, ya había sido identificada en el texto de entrenamiento. El resto han sido categorizadas, también acertadamente, con la etiqueta por defecto: NCMP (nombre común masculino plural) si acaban en *-s* y NCMS (nombre común masculino singular) en caso contrario. La implementación de estas etiquetas por defecto ha resultado ser, pues, una buena elección para la identificación de palabras inglesas.

3.1.3 Ambigüedad

El problema de la ambigüedad ha persistido, como era de esperar. En particular, han continuado resultando problemáticas las palabras terminadas en *-ado(s)*, *-ada(s)*. Las cuatro palabras del texto con esta terminación (*diseñado*, *resultado*, *indeseado* y *denominados*) han sido categorizadas como adjetivos, cuando solo una lo es (*indeseado*). Un caso análogo ha sido el de la palabra *conocido*, con terminación *-ido*. Otro error del analizador debido a ambigüedad ha sido la categorización de la palabra *uno* en el sintagma *uno o diversos tipos de tareas,* que ha sido etiquetada como pronombre.

3.1.4 Formas verbales acabadas en *-a*

Otro error usual de nuestro analizador ha sido el etiquetado de las formas verbales terminadas en *-a* como nombres femeninos. Ese tipo de error ya se había detectado y se había intentado corregir, añadiendo en el diccionario las formas verbales del texto de entrenamiento que no estaban contempladas en reglas específicas. Sin embargo, las formas verbales que no aparecían en ese texto no se incluyeron, de modo que el analizador automático ha fallado en estos casos: *diferencia*, *usa*, *asemeja*, *desencadena*...

3.1.5 Consecuencias de la elección de las categoría por defecto

Otro error a destacar en el análisis del texto de test por nuestro sistema automático ha sido la etiquetación incorrecta de nombres singulares acabados en *-s* como plurales y de nombres masculinos acabados en *-a* como femeninos: *inglés*, *problema*.

3.2 Conclusiones

Tras analizar los resultados obtenidos por nuestra herramienta podemos concluir que la combinación de expresiones regulares y diccionarios es una buena aproximación para la implementación de analizadores morfológicos dentro de un cierto dominio. Nuestra herramienta, construida con solo un texto de 661, ha obtenido una tasa de aciertos del 90%. Esta tasa podría aumentarse significativamente con la inclusión de expresiones regulares para otras terminaciones características y, sobre todo, mediante la adición al diccionario de más palabras del dominio, sacadas de corpus más grandes que el nuestro.

References

[Padró 2012] Padró, Lluís y Stanilovsky, Evgeny, *FreeLing 3.0: Towards Wider Multilinguality*, Proceedings of the Language Resources and Evaluation Conference (LREC 2012) ELRA

[Meaning Cloud] Meaning Cloud, *Diccionario Inverso Stilus*, www.mystilus.com/Diccionario_Inverso

Anexo 1: Diagrama de flujo del procedimiento para la asignación de etiquetas, creación de expresiones regulares e inclusión de palabras en el diccionario

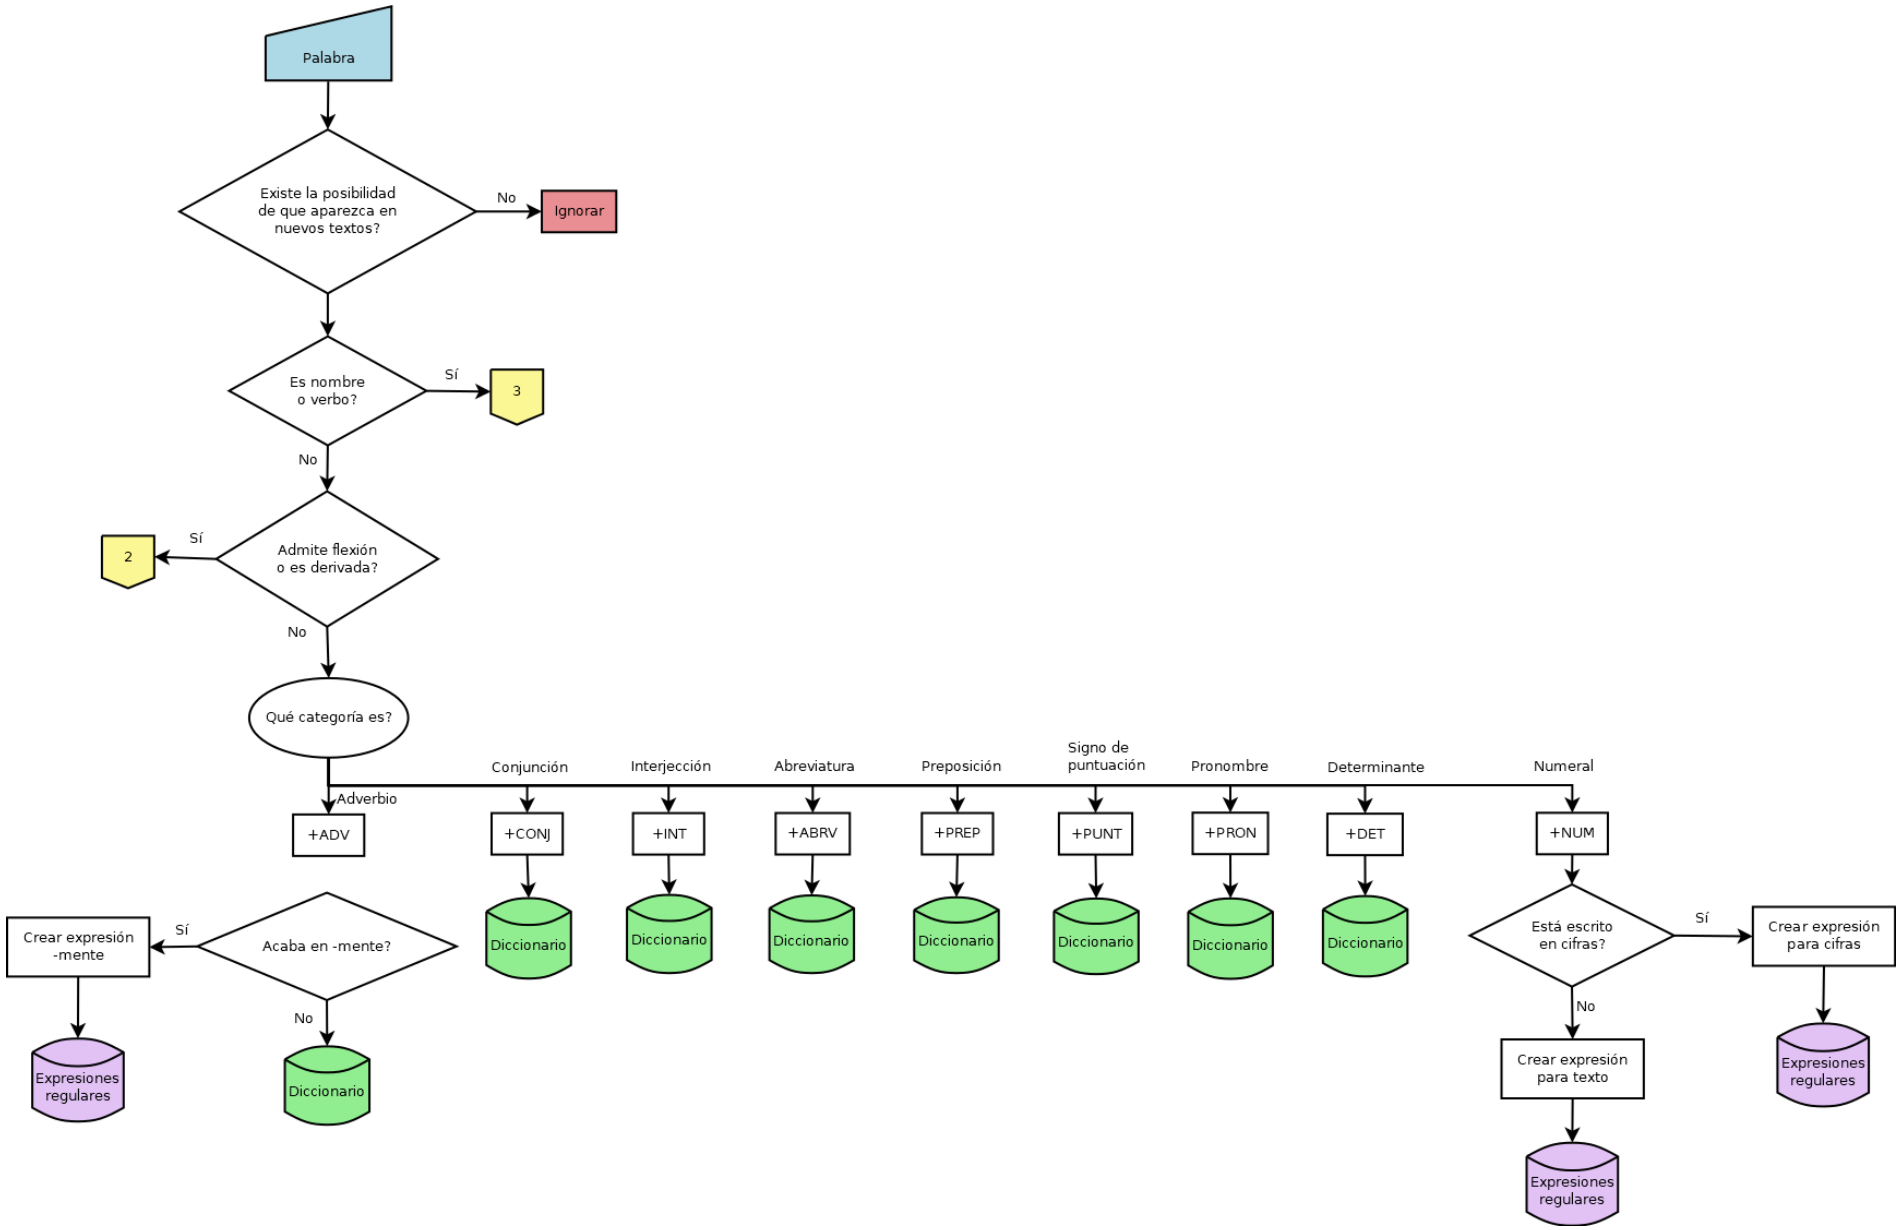

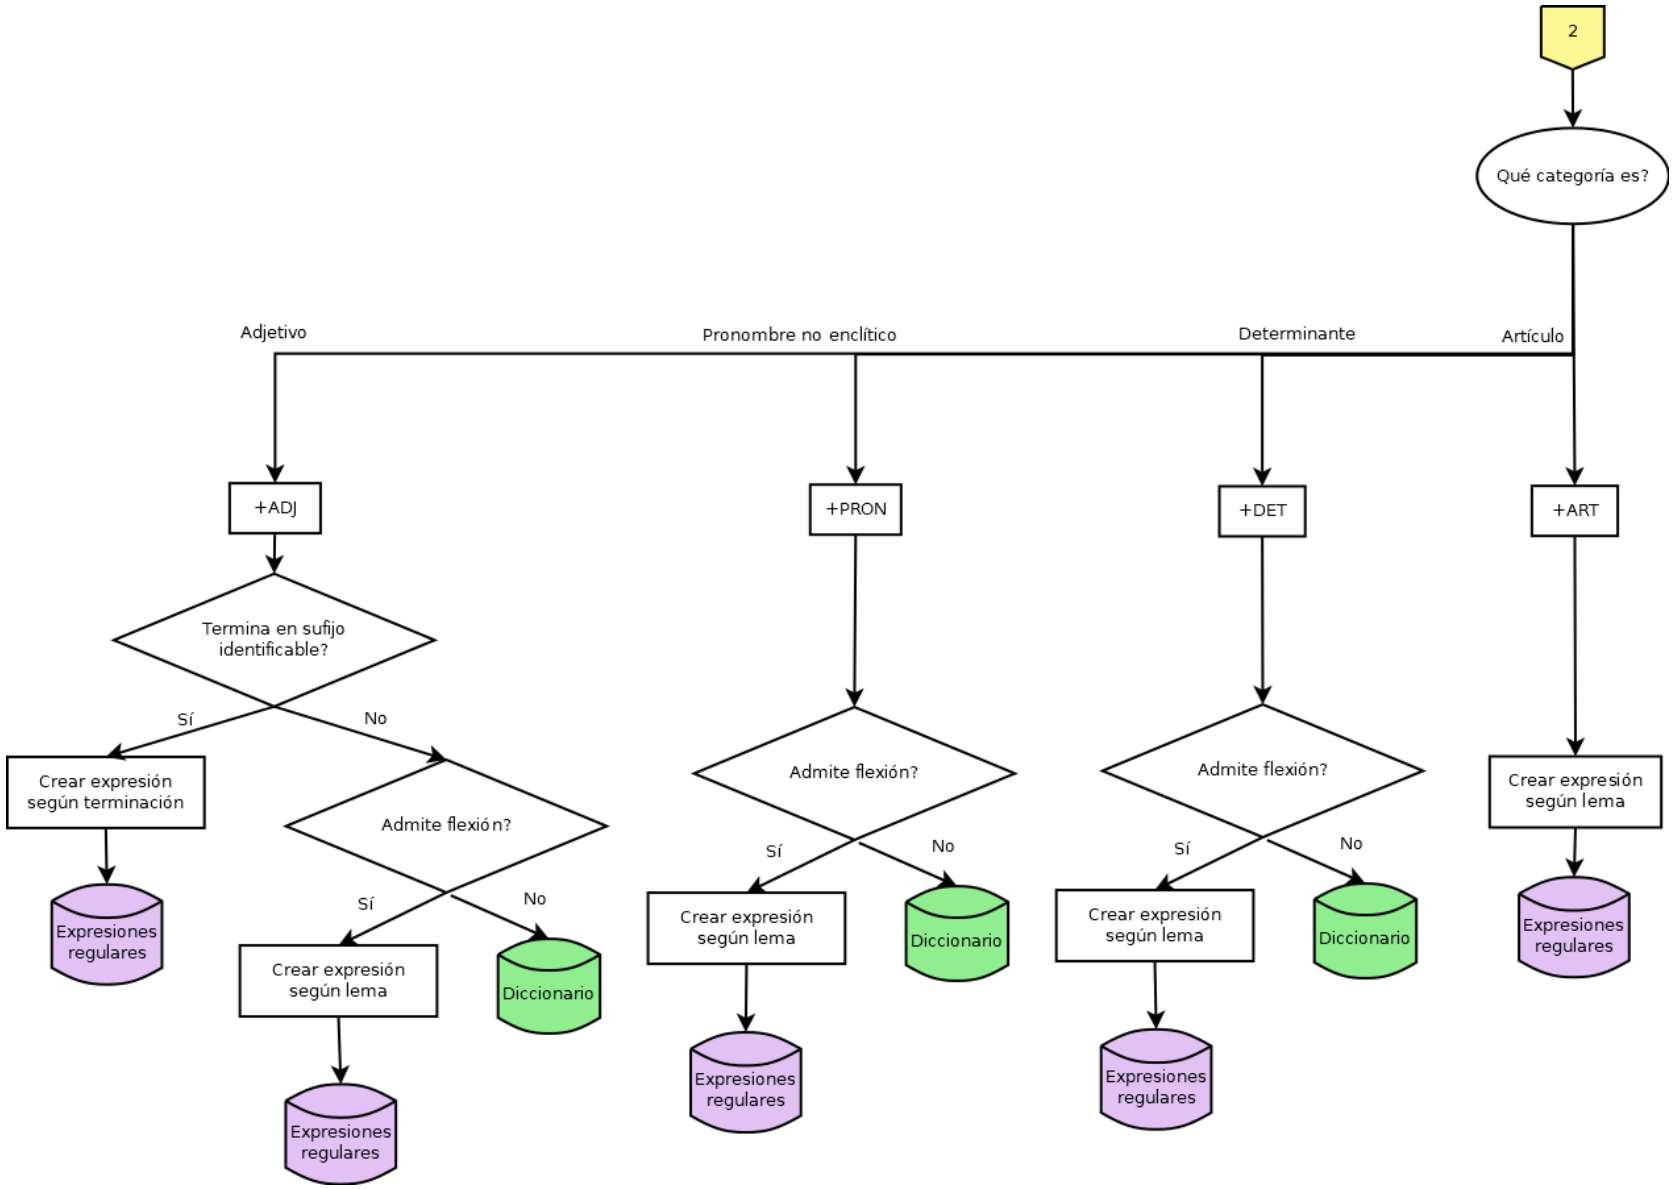
2
Qué categoría es?
Adjetivo
Pronombre no enclítico
Determinante
Artículo
+ADJ
+PRON
+DET
+ART
Termina en sufijo identificable?
Sí
No
Crear expresión según terminación
Expresiones regulares
Admite flexión?
Sí
No
Crear expresión según lema
Expresiones regulares
Diccionario
Admite flexión?
Sí
No
Crear expresión según lema
Expresiones regulares
Diccionario
Admite flexión?
Sí
No
Crear expresión según lema
Expresiones regulares
Diccionario
Crear expresión según lema
Expresiones regulares

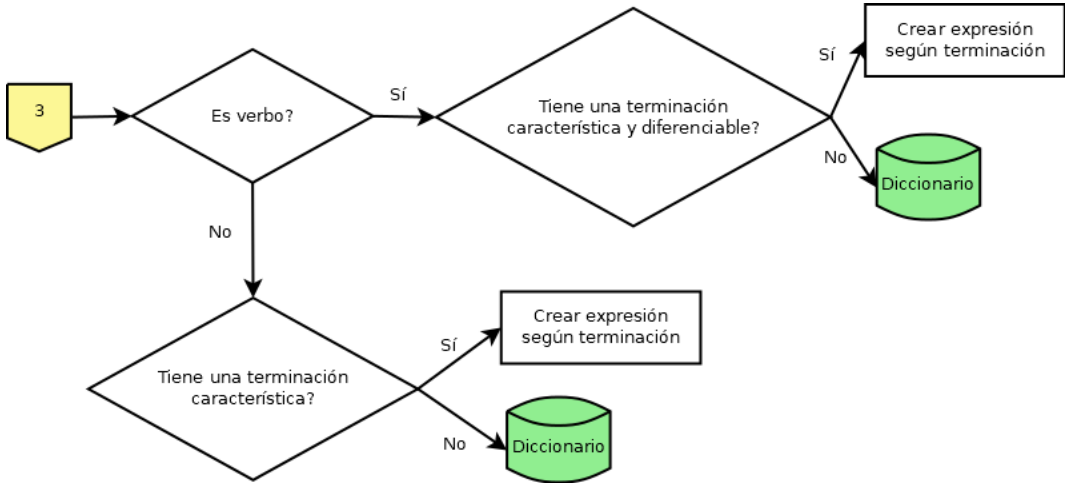
3
Es verbo?
Sí
Tiene una terminación característica y diferenciable?
Sí
Crear expresión según terminación
No
Diccionario
No
Tiene una terminación característica?
Sí
Crear expresión según terminación
No
Diccionario